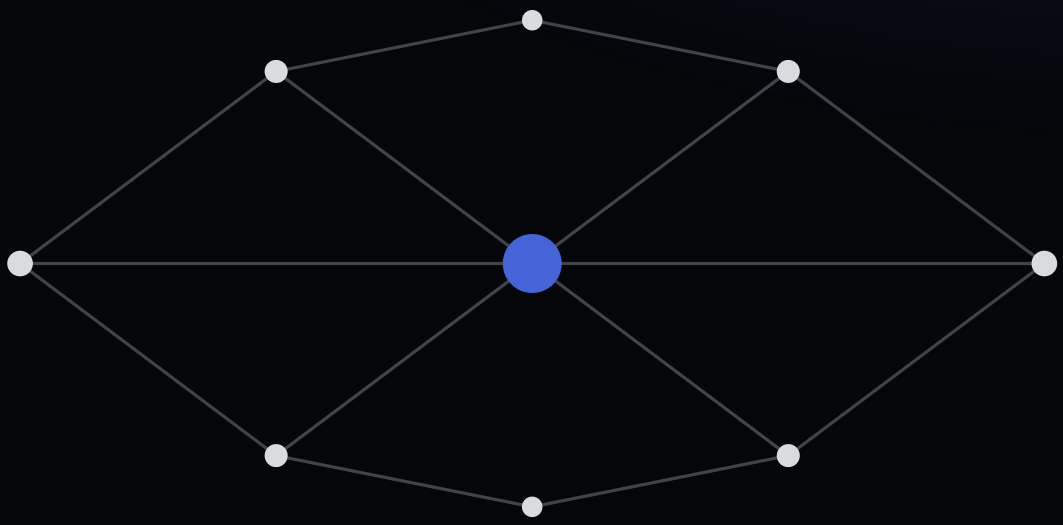
LIVRE BLANC · 2026

La transformation agentique

Passer des assistants aux agents : méthode, gouvernance et feuille de route pour transformer des processus d'entreprise.



Yassine Aqejjaj

Head of AI Factory, Devoteam

VERSION 1.0
NOVEMBRE 2026
IASEEN.COM

SOMMAIRE

Ce que vous allez trouver

01 **Ce que « agentique » change vraiment**
Du assistant au système multi-agents

02 **Choisir les processus à transformer**
Une grille de sélection et une matrice valeur / risque

03 **Concevoir la place de l'humain**
Rôles, points de décision, niveaux d'autonomie

04 **Architecture d'un système agentique**
Orchestration, spécialistes, contexte, évaluation

05 **Contexte, données et droits**
Le contexte comme produit gouverné

06 **Évaluer avant d'étendre**
Scénarios, juges, revue humaine, portes de production

07 **Gouverner les actions**
Politiques, validation, traçabilité

08 **Conduire le changement**
Métiers, compétences, adoption

09 **Mesurer la transformation**
Quatre familles d'indicateurs

10 **Feuille de route par vagues**
Assister, déléguer, superviser

11 **Les erreurs à éviter**
Symptômes, causes, remèdes

A **Annexes**
Grille, fiche d'agent, checklist, glossaire

COMMENT LIRE CE GUIDE

Les chapitres 1 à 3 posent les idées : ce qu'est un agent, quoi transformer, où mettre l'humain. Les chapitres 4 à 7 détaillent la mécanique, les chapitres 8 à 10 la conduite du changement et la feuille de route. Les annexes contiennent des modèles à copier.

RÉSUMÉ EXÉCUTIF

Six idées à retenir

1. Un agent agit, il ne se contente pas de répondre

La rupture n'est pas la qualité des réponses mais la capacité à planifier et à agir avec des outils. C'est ce qui crée la valeur, et ce qui crée le risque.

2. On transforme des processus, pas des outils

Le bon point de départ n'est pas la technologie mais une liste de processus notés sur la valeur, le risque, les données et l'évaluabilité.

3. L'autonomie se gagne

Quatre niveaux, de la suggestion à la supervision. On monte d'un niveau à la fois, avec des preuves, et on redescend après un incident.

4. Le contexte et l'évaluation font la fiabilité

Les échecs viennent plus souvent d'un contexte périmé ou mal autorisé que du modèle. Aucune extension d'usage sans scénarios de test passés.

5. Le changement est humain

Les métiers changent de rôle : de l'exécution vers la supervision. La formation par la pratique fait partie du produit.

6. Se déroule par vagues, se mesure en continu

Assister d'abord, déléguer ensuite, superviser enfin, avec quatre familles d'indicateurs et un point de contrôle à chaque vague.

REPÈRES, PLATEFORME AGENTIQUE NOVA (AI FACTORY DE DEVOTEAM)

800	92 %	-42 %	15
collaborateurs utilisent la plateforme	de réussite des tâches	de temps d'exécution des tâches	personnes dans l'équipe pluridisciplinaire

01

Ce que « agentique » change vraiment

Un agent ne répond pas seulement : il planifie et agit.

DÉFINITION

Un système agentique est un système où un modèle de langage décide de la suite des étapes et agit avec des outils pour atteindre un objectif, dans un cadre de droits, de limites et de contrôle défini par l'organisation.

Le mot est à la mode, le changement est réel

Pendant deux ans, l'IA générative s'est surtout déployée sous forme d'assistants : on pose une question, on obtient une réponse. Le changement n'est pas que les réponses sont meilleures. C'est que le système peut maintenant **enchaîner des étapes, consulter des sources, appeler des outils et produire un livrable**, sans qu'un humain décrive chaque étape. La valeur monte, et le risque aussi.

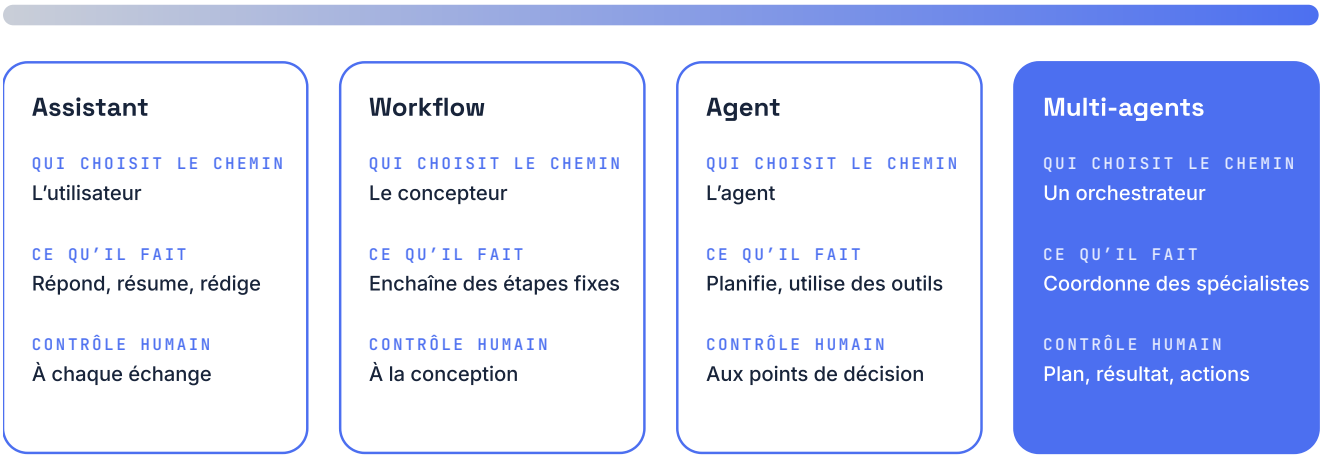


FIGURE 1 Quatre familles de systèmes, classées par autonomie croissante. Chaque famille a sa place : la bonne est la moins autonome qui résout le problème.

Trois idées reçues

« Plus d'autonomie, c'est mieux »

Non : la bonne autonomie est la plus faible qui suffit. Chaque niveau coûte en évaluation et en supervision.

« Un meilleur modèle règle tout »

Les échecs viennent plus souvent d'un contexte périmé, de droits mal appliqués ou d'une évaluation absente.

« On déploie, puis on évalue »

L'ordre inverse : on évalue sur des scénarios fixes avant d'étendre l'usage ou les droits.

Choisir la bonne famille

Le réflexe est de viser le niveau le plus avancé. C'est rarement le bon : l'autonomie coûte en évaluation, en gouvernance et en supervision. La règle que je recommande est simple : **prendre la famille la moins autonome qui résout le problème**.

CRITÈRE	ASSISTANT	WORKFLOW	AGENT	MULTI-AGENTS
Chemin connu à l'avance ?	Peu importe	Oui, fixe	Non, varie selon le cas	Non, et il se découpe en spécialités
Nombre d'étapes	Une	Quelques-unes, stables	Plusieurs, variables	Beaucoup, à coordonner
Outils à utiliser	Aucun ou peu	Fixes	Choisis par l'agent	Répartis entre spécialistes
Coût d'une erreur	Faible, corrigée par l'utilisateur	Maîtrisé par la conception	À encadrer	À encadrer fortement
Effort d'évaluation	Léger	Léger	Significatif	Élevé
Exemple de besoin	Reformuler un texte	Router une demande vers une équipe	Préparer un dossier à partir de sources	Produire un livrable avec plusieurs expertises

Ce que ça change pour l'entreprise

Avant : l'humain exécute

- il cherche l'information ;
- il assemble les éléments ;
- il produit le livrable ;
- il vérifie à la main.

Après : l'humain supervise

- il formule l'objectif ;
- il valide le plan et les actions critiques ;
- il relit le livrable et ses sources ;
- il corrige et améliore le système.

MON ANALYSE

La vraie transformation n'est pas la technologie, c'est le déplacement du travail humain de l'exécution vers la supervision. Une organisation qui n'a pas préparé ses équipes à superviser verra l'agent produire plus vite des erreurs qu'on ne sait pas détecter.

02

Choisir les processus à transformer

On ne transforme pas une technologie : on transforme des processus, choisis sur des critères explicites.

La plupart des programmes agentiques démarrent par un outil et cherchent ensuite à l'utiliser. Le meilleur ordre est inverse : **dresser la liste des processus candidats**, les noter, et ne retenir que ceux où un agent apporte plus qu'un workflow ou qu'un assistant.

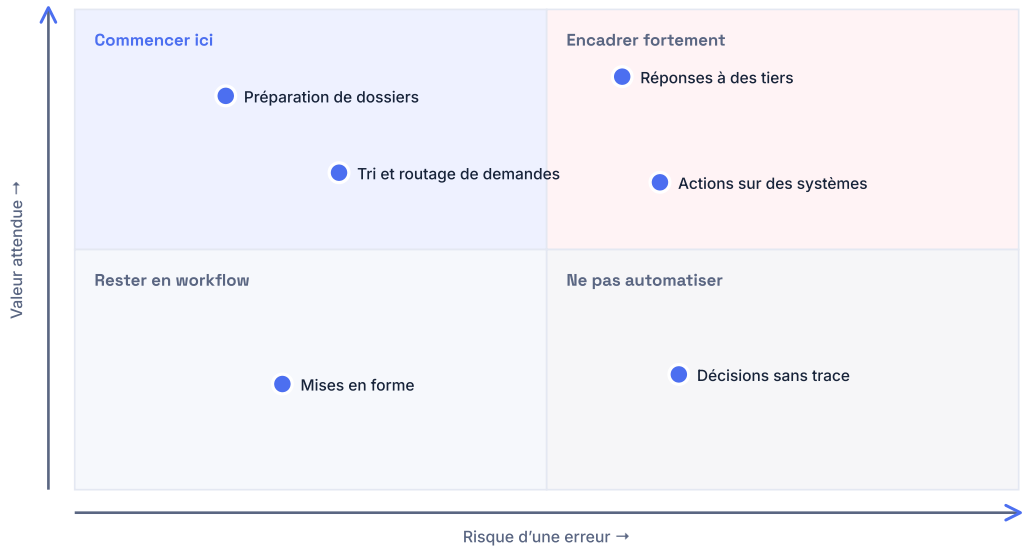


FIGURE 2 Matrice valeur / risque. On commence dans le quadrant à forte valeur et à faible risque ; le quadrant à fort risque demande un niveau d'autonomie bas et une validation humaine. Les points sont des exemples génériques à placer selon votre contexte.

Familles de processus et pattern souvent adapté

FAMILLE	EXEMPLE GÉNÉRIQUE	PATTERN SOUVENT ADAPTÉ
Questions sur un corpus	Interroger une base documentaire interne	Assistant avec récupération
Routage et qualification	Orienter une demande vers la bonne équipe	Workflow, avec un modèle pour classer
Préparation de dossiers	Assembler des éléments de plusieurs sources	Agent, supervisé
Livrables multi-expertises	Un document qui demande plusieurs spécialités	Multi-agents, orchestré
Actions sur des systèmes	Mettre à jour un enregistrement	Agent sous politique et validation

À titre d'illustration : à classer selon votre contexte.

La grille de sélection d'un processus

Notez chaque critère de 0 à 3. Le but est de comparer des processus entre eux, pas d'atteindre un score absolu.

CRITÈRE	QUESTION	UN BON CANDIDAT…
Valeur	Quel gain, mesuré comment, attendu par qui ?	A un responsable métier qui attend le résultat
Fréquence	Combien de fois par semaine le processus se répète-t-il ?	Se répète assez pour amortir l'effort de mise en place
Variabilité	Le chemin change-t-il d'un cas à l'autre ?	Varie assez pour qu'un workflow fixe ne suffise pas
Données	Les sources sont-elles accessibles, à jour, autorisées ?	Repose sur des sources identifiées et gouvernées
Risque	Une erreur est-elle réversible et détectable ?	Reste détectable par un humain avant tout effet
Évaluabilité	Sait-on décrire un bon résultat et le mesurer ?	A des critères écrits et des cas de test
Adoption	Les utilisateurs sont-ils prêts à changer leur façon de faire ?	A des utilisateurs identifiés et motivés

De la liste de processus à la décision

1. **Recenser** vingt à trente processus avec les responsables métier, sans filtrer.
2. **Noter** sur la grille, en atelier, avec les équipes qui les exécutent.
3. **Placer** chacun dans la matrice valeur / risque et écarter ceux du quadrant « ne pas automatiser ».
4. **Choisir la famille** (workflow, agent…) la moins autonome qui convienne à chacun.
5. **Retenir deux ou trois processus pilotes**, pas dix : l'évaluation et la supervision demandent de l'attention.

MON ANALYSE

Le meilleur processus pilote n'est pas le plus spectaculaire. C'est celui où l'on sait dire ce qu'est un bon résultat, où une erreur coûte peu et où quelqu'un attend vraiment le livrable.

03

Concevoir la place de l'humain

Superviser ne veut pas dire tout relire : on place l'humain là où son jugement compte.

« Humain dans la boucle » ne signifie pas validation de chaque étape, ce qui annulerait le gain. Cela signifie des **points de décision explicites**, placés là où une erreur coûte le plus ou là où le jugement métier est irremplaçable.

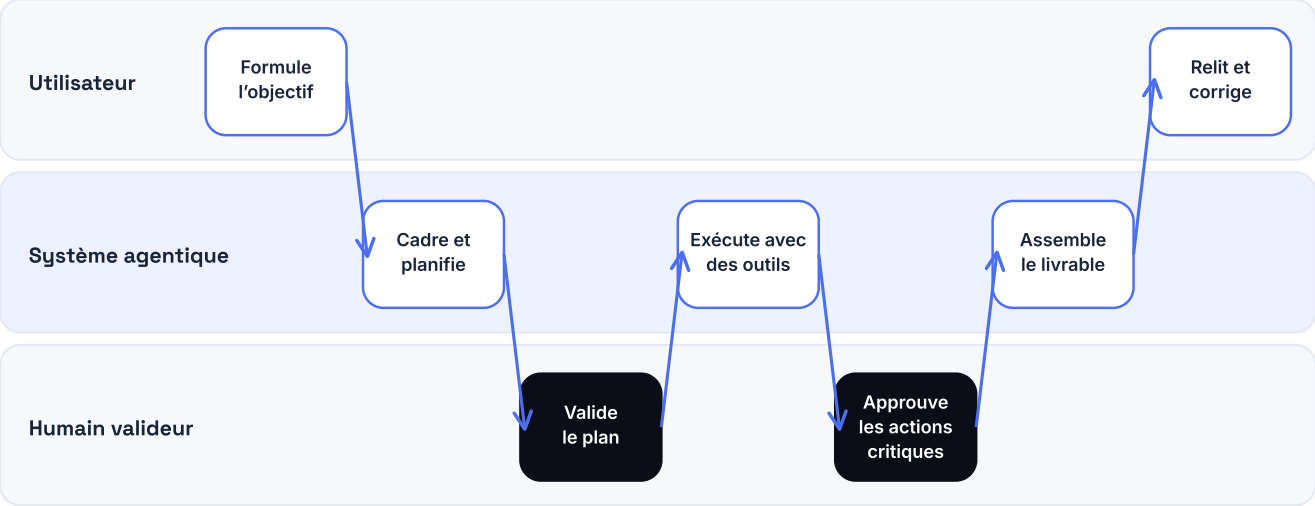


FIGURE 3 Un parcours type : l'humain formule, valide le plan, approuve les actions critiques, puis relit le livrable.

Les trois rôles humains

Le demandeur

Exprime l'objectif et utilise le résultat. Il doit savoir ce qu'il peut demander et comment vérifier.

Le superviseur

Valide les plans et les actions critiques. Il a l'autorité et le temps pour refuser.

Le responsable du système

Possède les critères, les scénarios et les niveaux d'autonomie. Il décide de monter ou de baisser l'autonomie.

Trois points de décision à ne pas oublier

1. **Le plan.** Avant d'exécuter, l'humain voit ce que l'agent compte faire et peut l'arrêter ou le corriger.
2. **Les actions critiques.** Envoi, modification, paiement : une validation proportionnée à la conséquence.
3. **Le livrable.** La relecture se fait avec les sources affichées, pas à l'aveugle.

Quatre niveaux d'autonomie, gagnés un par un

L'autonomie n'est pas une propriété du modèle : c'est un **statut gagné par type de travail**. J'utilise une échelle à quatre niveaux, issue d'un cadre public pour les agents de code, transposable à d'autres usages.

NIVEAU	L'AGENT PEUT	L'HUMAIN DOIT ENCORE	ON MONTE QUAND…
L0 · Suggérer	Proposer des options et des brouillons	Décider et écrire le changement	Les suggestions sont régulièrement utiles
L1 · Assister	Produire en petites étapes	Relire chaque modification	Les relectures ne trouvent plus d'erreur sur un échantillon représentatif
L2 · Déléguer	Accomplir une tâche bornée et la soumettre	La relire et passer les contrôles	Les scénarios de test sont passés et les incidents sont rares
L3 · Superviser	Vérifier et appliquer dans un environnement non productif	Auditer des échantillons et approuver la mise en production	—

DEUX RÈGLES DE PRUDENCE

Jamais au-dessus de L1 pour des actions irréversibles ou des données sensibles. Et l'autonomie baisse d'un niveau après tout incident : elle ne remonte qu'avec des preuves.

Les niveaux de risque d'une action

TYPE D'ACTION	EXEMPLE	CONTRÔLE ATTENDU
Lecture seule	Résumer un document autorisé	Droits d'accès, sources affichées
Écriture réversible	Brouillon dans un outil de projet	Journal, annulation possible
Action coûteuse ou externe	Envoyer un message ou lancer un paiement	Validation humaine avant exécution
Hors périmètre	Accéder à des données non autorisées	Blocage par politique, alerte

MON ANALYSE

La question à poser n'est pas « l'agent est-il assez bon ? » mais « que se passe-t-il quand il se trompe, et qui le voit ? ». Le niveau d'autonomie se déduit de la réponse.

04

Architecture d'un système agentique

Un agent à qui parler, des spécialistes derrière, un contexte gouverné dessous, une évaluation autour.

Un système agentique d'entreprise n'est pas « un modèle plus des outils ». C'est un assemblage de couches, chacune avec sa responsabilité et sa question de conception. Ce découpage vient de la plateforme agentique que je dirige ; il s'applique à d'autres.



FIGURE 4 Architecture en couches d'un système agentique. L'évaluation entoure l'ensemble : chaque résultat revient dans le contexte et le comportement.

COUCHE	RÔLE	QUESTION DE CONCEPTION
Orchestration	Un seul interlocuteur : il cadre, planifie, délègue, supervise	Comment éviter que l'utilisateur doive connaître l'organigramme des agents ?
Contexte	Récupérer le bon contenu, au bon moment, avec les bons droits	Que sait-on, d'où, pour qui, depuis quand, et pourquoi cet élément a-t-il été retenu ?
Spécialistes	Un agent par profil, avec des compétences versionnées	Où l'autonomie est-elle utile, où vaut-il mieux un flux fixe ?
Évaluation	Mesurer chaque version avant et après passage à l'échelle	Quels scénarios, quels critères, quel seuil de décision ?

Cinq principes d'assemblage

1. **Un seul interlocuteur.** L'utilisateur ne choisit jamais un agent : l'orchestrateur le fait pour lui. C'est la principale décision d'adoption, bien avant la qualité du modèle.
2. **Le contexte est un produit, pas une instruction.** Il a un propriétaire, un cycle de vie et une piste d'audit.
3. **Des compétences versionnées.** Les workflows d'agents sont testés, versionnés et réutilisables, comme du code.
4. **Des livrables structurés.** Le résultat n'est pas un message de chat à copier : c'est un livrable versionné, éditable, avec ses sources.
5. **Tout composant est évalué avant d'être étendu** à une autre équipe.

Ce que montrent les indicateurs de la plateforme NOVA

Les indicateurs ci-dessous viennent de la plateforme agentique de l'AI Factory de Devoteam. Ils illustrent ce qu'on peut mesurer pour chaque couche. La méthode de calcul, le périmètre et la période de mesure sont communiqués sur demande.

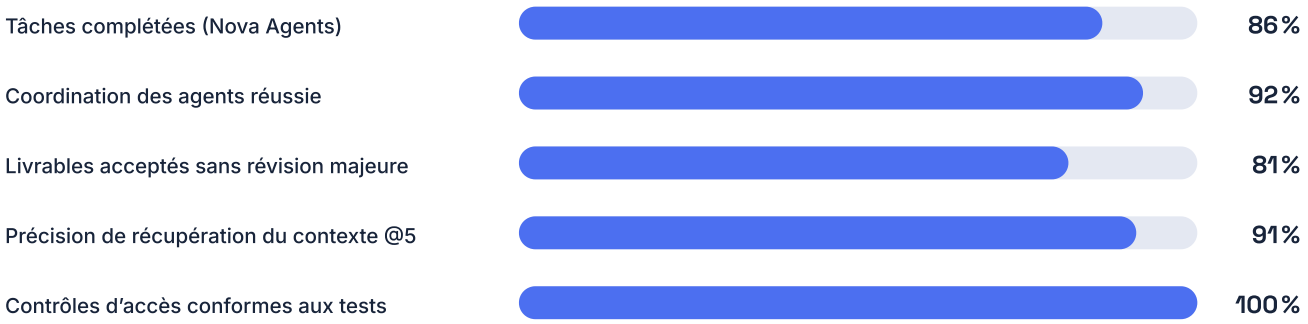


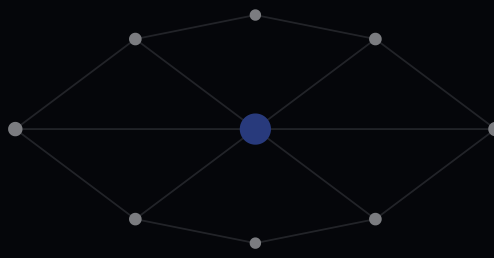
FIGURE 5 Indicateurs par couche de la plateforme NOVA (agents, contexte). Source : AI Factory de Devoteam.

> PRÉCAUTION
>
> Les projets publics que je cite en fin de guide sont des dépôts en bêta publique : ils décrivent une conception, pas une garantie de production.

05

Contexte, données et droits

La plupart des échecs d'agents ne sont pas des échecs du modèle : ce sont des échecs de contexte.



Un agent qui cite une décision remplacée depuis un mois, qui mélange deux versions d'une spécification, ou pire qui expose un document à quelqu'un qui n'a pas le droit de le voir : ces échecs ne se règlent pas en changeant de modèle. Ils se règlent en traitant le **contexte comme un produit gouverné**.

SUJET	CE QU'UN SYSTÈME NAÏF FAIT	CE QU'UN SYSTÈME GOUVERNÉ FAIT
Fraîcheur	Récupère le passage le plus proche, même périmé	Tient compte de la date et de l'état de validité de l'information
Contradictions	Cite deux sources contradictoires sans le signaler	Détecte les conflits et les fait arbitrer
Droits d'accès	Ouvre tout ce que la connexion technique permet	Applique les droits de l'utilisateur, de bout en bout
Données sensibles	Les mélange au reste	Détecte, classe et masque, et propage le classement
Explication	Donne une réponse sans trace	Dit pourquoi un élément a été retenu ou écarté
Coût	Envoie tout le contexte possible au modèle	Applique un budget et mesure le coût par requête

Quatre règles pour les données

- **Une source de vérité par donnée.** Dupliquer les documents dans chaque projet multiplie les fuites et les versions périmées.
- **Propager les droits.** L'agent ne voit que ce que l'utilisateur peut voir, quel que soit le chemin d'accès.
- **Classer les données** et faire suivre le classement jusqu'à la réponse.
- **Tester les droits comme du code :** des cas de test d'accès font partie des scénarios d'évaluation.

MON ANALYSE

Les prochains gains des agents d'entreprise viendront du contexte, pas de modèles plus gros. Si l'on ne peut pas expliquer pourquoi un élément est arrivé dans l'invite de l'agent, on ne contrôle pas encore son agent.

06

Évaluer avant d'étendre

On ne confie pas plus d'autonomie à ce qu'on ne sait pas mesurer.

Un système agentique change à chaque modification de consigne, d'outil, de modèle ou de contexte. Sans jeu de scénarios fixe, personne ne distingue une amélioration d'une régression. L'évaluation traite chaque version comme une **expérience** : mêmes scénarios, une référence contre un candidat, avec scores, coût, erreurs et niveau de confiance.

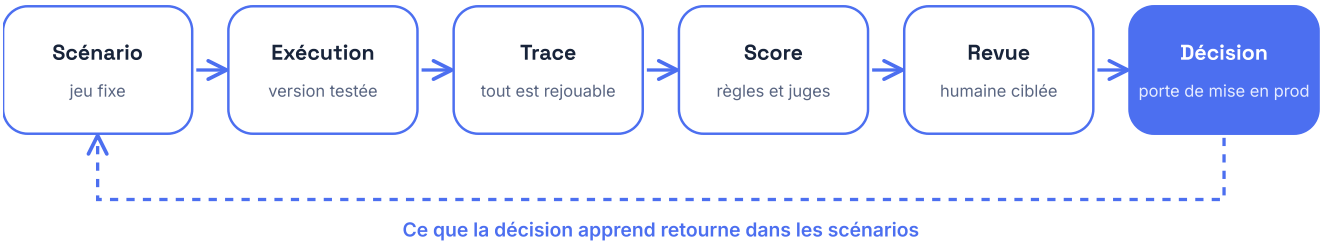


FIGURE 6 La boucle d'évaluation d'un système agentique.

COUCHE D'ÉVALUATION	CE QU'ELLE ATTRAPE	SA LIMITE
Règles déterministes	Format, citations, sources absentes, données personnelles, outil interdit, coût ou latence hors budget	Ne juge pas si une réponse est vraiment bonne
Juges automatiques	Qualité, cohérence et raisonnement par rapport à une grille écrite	Ont leurs biais ; à calibrer sur des jugements humains
Revue humaine	Erreurs subtiles, ton, justesse métier	Lente et coûteuse : à cibler sur les cas critiques
Traces	Quel appel de modèle, d'outil ou de récupération a échoué	Explique un échec, ne dit pas s'il faut le corriger
Scénarios cachés ou nouveaux	Sur-optimisation : un système réglé sur des tests publics échoue sur du nouveau	Valent ce que valent leur fraîcheur et leur représentativité

Quatre questions pour une revue de scénarios

1. Les scénarios ressemblent-ils à des cas réels, y compris des cas limites ?
2. Qui a écrit les critères, et le métier les a-t-il validés ?
3. Que se passe-t-il sur des cas jamais vus ?
4. Quand un résultat échoue, sait-on dire pourquoi ?

Une porte de mise en production, avant tout élargissement

L'évaluation ne sert que si elle débouche sur une décision. La porte de mise en production est un ensemble de critères **écrits à l'avance**, que la version candidate doit satisfaire avant d'être étendue à plus d'utilisateurs ou d'actions.

CRITÈRE DE PORTE	EXEMPLE DE FORMULATION	QUI DÉCIDE
Qualité	Au moins X % des scénarios prioritaires réussis, sans régression sur les scénarios déjà acquis	Responsable de l'évaluation
Sécurité et droits	Tous les cas de test d'accès sont conformes ; aucune donnée sensible exposée	Gouvernance et sécurité
Coût et délai	Coût par requête et latence dans le budget	Responsable du système
Supervision	Les points de validation humaine sont en place pour les actions à risque	Responsable métier

Les seuils chiffrés (X) sont à fixer avec le métier selon le risque du processus : ils ne se copient pas d'une organisation à l'autre.

Un exemple d'indicateurs d'évaluation



FIGURE 7 Indicateurs de la couche d'évaluation de la plateforme NOVA. Source : AI Factory de Devoteam.

LECTURE

Un accord de 89 % entre juge automatique et humain ne veut pas dire que le juge est « bon à 89 % » : cela veut dire qu'il est calibré contre des jugements humains sur un jeu de cas. C'est cette calibration qui permet de s'appuyer ensuite sur lui pour passer à l'échelle.

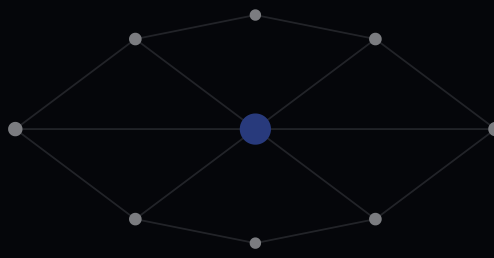
MON ANALYSE

L'évaluation est le plan de contrôle d'une plateforme agentique. Sans elle, chaque version est un pari. Avec elle, on peut donner plus d'autonomie aux agents, parce qu'on peut montrer ce qui se passe.

07

Gouverner les actions

Dès qu'un agent agit, la gouvernance change de nature : il ne s'agit plus de contrôler des textes, mais des effets.



Un chatbot qui se trompe produit un mauvais texte. Un agent qui se trompe produit une mauvaise **action** : un message envoyé, un enregistrement modifié, un paiement lancé. La gouvernance doit donc porter sur ce que l'agent a le droit de faire, pas seulement sur ce qu'il peut dire.

Les quatre fonctions d'une gouvernance d'actions

FONCTION	CE QU'ELLE GARANTIT	QUESTION À POSER
Politique	Ce que l'agent peut faire, sur quelles ressources, avec quelles limites	Qui a écrit la règle, et est-elle appliquée hors du modèle ?
Approbation	Une validation humaine proportionnée à la conséquence	Quelles actions exigent un humain, et lequel ?
Traçabilité	Une preuve vérifiable de ce qui a été demandé, décidé et fait	Peut-on rejouer et prouver ce qui s'est passé ?
Révocation	Retirer ou réduire des droits rapidement	Que se passe-t-il quand un incident survient ?

Cinq règles de gouvernance

1. Un agent est un **demandeur non fiable** : la politique est décidée hors du modèle.
2. L'approbation humaine dépend de la **conséquence** de l'action, pas de sa nouveauté.
3. L'autonomie baisse d'un niveau après un incident et ne remonte qu'avec des preuves.
4. Tout ce qui agit laisse une **trace vérifiable** : qui, quoi, sous quelle politique.
5. Les environnements d'essai utilisent des **données synthétiques** avant toute donnée réelle.

MA PRATIQUE

Je teste des politiques, des validations humaines et des reçus signés sur des environnements d'essai synthétiques. Ce sont des études de conception, pas des systèmes en production.

MON ANALYSE

L'approbation humaine doit dépendre de la conséquence, pas de la nouveauté. Un agent qui demande une validation pour tout finit par être contourné ; un agent qui n'en demande jamais finit par provoquer l'incident.

08

Conduire le changement

Le travail humain se déplace de l'exécution vers la supervision : cela se prépare.

Une plateforme que personne ne sait utiliser est un coût. Le changement agentique touche les métiers en profondeur : ce qu'on demande à un collaborateur n'est plus de produire, mais de formuler, valider et améliorer. Les chiffres ci-dessous viennent de deux dispositifs que j'ai conçus au sein de l'AI Factory de Devoteam.

PROGRAMME DE FORMATION INTERNE (LEAP)

1500+	75+	4,6/5	+32 pts	68 %
professionnels formés	sessions animées	satisfaction	progression à l'évaluation des connaissances	appliquent leurs compétences après 30 jours

La pratique fait la différence

Une session de formation produit des enthousiastes. La pratique encadrée produit des habitudes. L'espace de pratique du prompting propose 13 parcours et 130 défis appliqués ; le score d'évaluation passe de 61 à 84 sur 100.

- 13 parcours d'apprentissage
- 130 défis appliqués
- 76 % de réussite aux défis

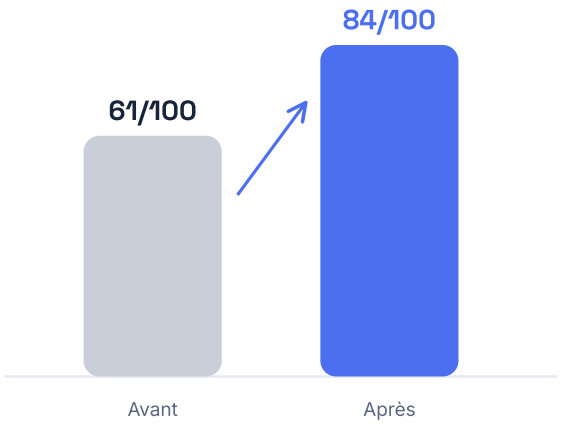


FIGURE 8 Score d'évaluation avant et après le parcours de pratique (sur 100).

Trois formats de formation

Atelier court

Découvrir ce qu'on peut demander à un agent et comment vérifier le résultat.

Parcours par rôle

Des défis appliqués à des tâches du métier, avec évaluation avant et après.

Communauté de champions

Des relais dans chaque équipe, qui remontent les frictions et diffusent les bonnes pratiques.

Ce qui change pour chaque population

POPULATION	CE QUI CHANGE	CE QU'IL FAUT LEUR DONNER
Collaborateurs métier	Ils formulent des objectifs, relisent des livrables, signalent les écarts	Formation par rôle, exemples de leur métier, droit de refuser un résultat
Managers	Ils supervisent des équipes qui travaillent avec des agents	Indicateurs d'usage, règles d'approbation, temps pour superviser
Équipes IT et sécurité	Elles gouvernent des actions et plus seulement des accès	Politiques lisibles, traces, outils de révocation
Direction	Elle arbitre un portefeuille de processus et accepte un risque encadré	Tableau de bord partagé, points de contrôle par vague

Cinq leviers d'adoption

LEVIER	CE QU'IL CHANGE	COMMENT LE METTRE EN PLACE
Formation par rôle	Les utilisateurs savent quoi demander et comment vérifier	Parcours courts, basés sur des tâches réelles du métier
Pratique encadrée	Les compétences deviennent des habitudes	Défis appliqués, retours, évaluation avant et après
Champions	Un relais de confiance dans chaque équipe	Un volontaire par équipe, un temps dédié, une communauté
Retours rapides	Les frictions sont corrigées vite	Un canal unique, un rythme de correction, des versions visibles
Mesure des usages	L'équipe voit ce qui marche	Taux d'usage, rétention, tâches réussies, temps gagné

PRINCIPE

On forme **par rôle** et à partir de **vraies tâches** : un juriste, un chef de projet et un ingénieur n'ont pas besoin du même parcours. Et on mesure ce qui se passe à trente jours, pas seulement la satisfaction du jour.

MON ANALYSE

Une transformation agentique qui ne forme pas à superviser produit des agents mal utilisés ou pas utilisés. La formation fait partie du produit, au même titre que l'interface.

09

Mesurer la transformation

Quatre familles d'indicateurs, relues chaque mois, avec leur méthode de calcul.

Une transformation agentique qui ne mesure pas se juge à l'intuition. Il ne s'agit pas de multiplier les tableaux de bord : quatre familles, trois à cinq indicateurs chacune.

FAMILLE	QUESTION POSÉE	INDICATEURS TYPES
Adoption	Les gens utilisent-ils le système ?	Utilisateurs actifs, rétention, usage par métier
Qualité	Les résultats sont-ils fiables ?	Taux de réussite des tâches, livrables acceptés, couverture d'évaluation, régressions détectées
Efficacité	Gagne-t-on du temps et de l'argent ?	Temps d'exécution, coût par requête, taux de réutilisation
Maîtrise	Garde-t-on le contrôle ?	Actions approuvées ou refusées, incidents, conformité aux tests de droits



FIGURE 9 Exemple de tableau de bord à quatre tuiles, avec les indicateurs de la plateforme NOVA. Source : AI Factory de Devoteam.

> LECTURE HONNÊTE
>
> La rétention à J7 (23 %) est le chiffre le plus bas et le plus utile : l'outil convainc à l'usage mais ne devient pas encore une habitude pour tous. C'est un chantier d'adoption, pas un problème de qualité. Un tableau de bord où tout est vert n'inspire pas confiance.

Trois règles pour des indicateurs crédibles

1. **Dire comment on calcule :** une valeur sans méthode, périmètre ni période de mesure ne convainc personne.
2. **Comparer à une référence mesurée** avant le déploiement, pas à une estimation.
3. **Montrer aussi ce qui va mal** et ce qu'on en fait.

10

Feuille de route par vagues

Assister d'abord, déléguer ensuite, superviser enfin : une trajectoire recommandée, à adapter.

Cette feuille de route est un **cadre recommandé**, pas le calendrier d'une organisation particulière. Les durées dépendent de la taille, de la maturité et de la disponibilité des données.

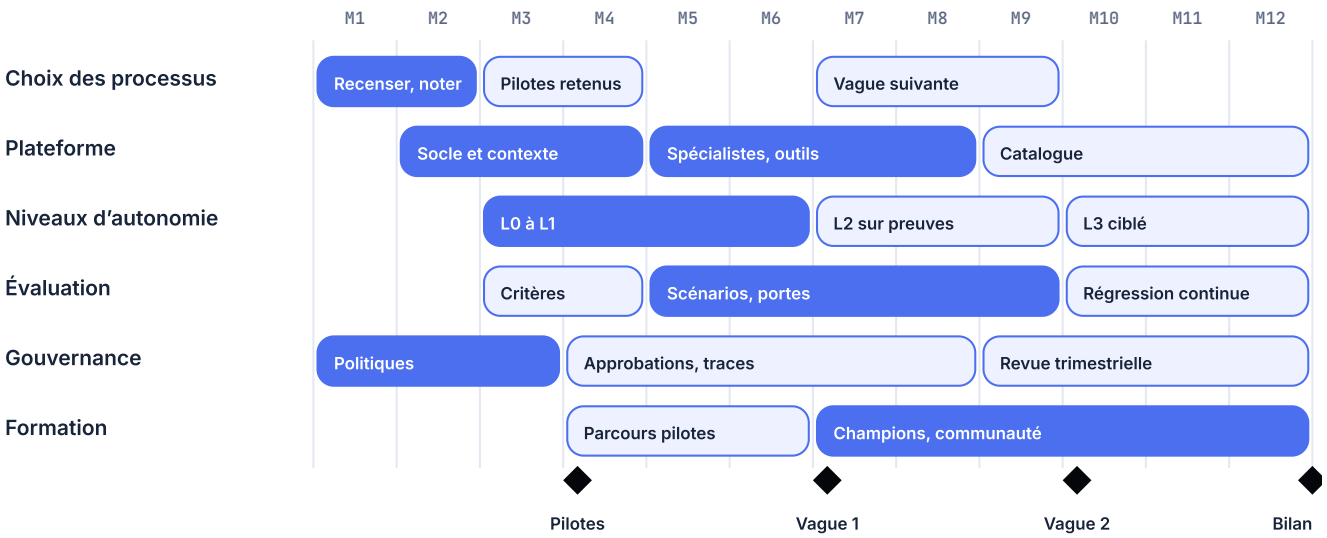


FIGURE 10 Feuille de route sur 12 mois par chantier. Les losanges marquent les points de contrôle.

VAGUE	OBJECTIF	NIVEAU D'AUTONOMIE	POINT DE CONTRÔLE
Pilotes (M1 à M3)	Deux ou trois processus choisis sur la grille, socle minimal, politiques écrites	L0 à L1	Les pilotes passent leurs scénarios et sont utilisés
Vague 1 (M4 à M6)	Mise en production restreinte, évaluation systématique, premiers champions	L1	Qualité, droits et coûts dans le budget
Vague 2 (M7 à M9)	Extension à de nouveaux processus, composants réutilisés	L2 sur preuves	Un deuxième processus réutilise les composants du premier
Vague 3 (M10 à M12)	Portefeuille de processus, supervision ciblée, bilan chiffré	L3 ciblé	Le coût et le délai du processus n sont inférieurs à ceux du processus 1

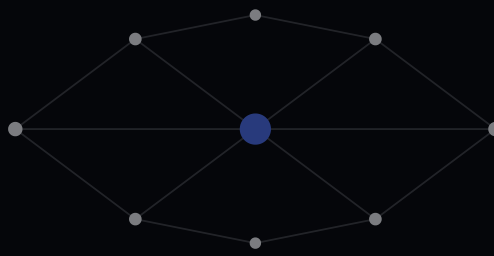
CE QU'IL FAUT PROTÉGER

Les trois premiers mois paraissent lents, mais ils décident de tout : un choix rigoureux des processus, des politiques écrites et une mesure de référence.

11

Les erreurs à éviter

Elles sont prévisibles, ce qui est la bonne nouvelle.



ERREUR	SYMPTÔME	CAUSE	REMÈDE
Partir de la technologie	Un outil brillant cherche un usage	Le point de départ est un modèle, pas un processus	Dresser et noter la liste des processus d'abord
Viser l'autonomie maximale	Des incidents et un retour en arrière	On saute les niveaux L0 et L1	Monter d'un niveau à la fois, sur des preuves
Évaluer à l'œil	Des régressions découvertes par les utilisateurs	On juge sur des démonstrations	Un jeu de scénarios fixe et une porte de mise en production
Négliger le contexte	Des réponses périmées ou non autorisées	Les sources ne sont pas gouvernées	Traiter le contexte comme un produit, tester les droits
Valider tout ou ne rien valider	Contournement ou incident	Aucune règle liée à la conséquence	Approbation proportionnée au risque de l'action
Oublier les équipes	Faible usage, quelques enthousiastes	Déploiement sans formation à superviser	Former par rôle, avec des champions et de la pratique
Des indicateurs sans méthode	Des chiffres qui ne convainquent personne	Pas de référence ni de périmètre	Documenter calcul, périmètre et période de mesure
Dix pilotes en parallèle	Aucun n'est évalué correctement	Pas de choix, donc pas d'attention	Deux ou trois pilotes, bien évalués et bien supervisés

MON ANALYSE

Si je devais retenir une seule règle : ne jamais donner à un agent plus d'autonomie que celle qu'on sait évaluer et superviser aujourd'hui. Tout le reste en découle.

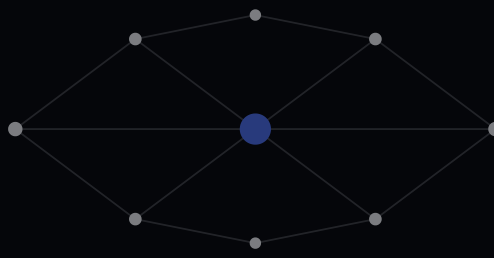
Cinq questions avant de lancer

1. Quel processus, et quel responsable métier l'attend ?
2. Quel niveau d'autonomie au démarrage, et pourquoi ?
3. Quels scénarios de test, et quelle porte de mise en production ?
4. Quelles actions exigent une validation humaine, et laquelle ?
5. Quel indicateur de succès, avec quelle référence mesurée ?

A

Annexes

Modèles à copier : grille de sélection, fiche d'agent, checklist de préparation.



A. Fiche d'un agent (cahier des charges)

RUBRIQUE	À ÉCRIRE
Mission	Ce que l'agent doit accomplir, pour qui, en une phrase
Périmètre	Les tâches incluses et exclues
Outils et sources	Les outils autorisés et les sources de données, avec leurs droits
Niveau d'autonomie	L0, L1, L2 ou L3, et les conditions pour changer
Points de validation	Les actions qui exigent une approbation humaine, et qui approuve
Scénarios de test	Les cas de test, y compris les droits d'accès et les cas limites
Indicateurs	Réussite des tâches, qualité, coût, temps, avec méthode de calcul
Responsable	Qui répond du comportement de l'agent

B. Checklist de préparation

Avant de commencer

- [ ] Liste de processus candidats, notée sur la grille
- [ ] Deux ou trois pilotes retenus
- [ ] Un sponsor et un responsable métier par pilote
- [ ] Une mesure de référence

Contexte et droits

- [ ] Sources gouvernées, une source de vérité par donnée
- [ ] Droits propagés de bout en bout
- [ ] Cas de test d'accès écrits

Évaluation et gouvernance

- [ ] Jeu de scénarios fixe par processus
- [ ] Niveaux d'autonomie et de risque écrits
- [ ] Validation humaine avant les actions coûteuses
- [ ] Porte de mise en production

Adoption et mesure

- [ ] Parcours de formation par rôle
- [ ] Un champion par équipe
- [ ] Tableau de bord à quatre familles

C. Glossaire

TERME	DÉFINITION
Agent	Programme qui utilise un modèle de langage pour planifier et agir avec des outils
Système multi-agents	Ensemble d'agents spécialisés coordonnés pour produire un résultat
Contexte	L'ensemble des informations fournies à un agent pour une tâche, avec leurs droits et leur provenance
Niveau d'autonomie	Degré de liberté d'un agent, gagné par type de travail
Évaluation de régression	Comparaison d'une version à une référence sur des scénarios fixes
Juge automatique	Modèle qui note des résultats selon une grille écrite, à calibrer sur des jugements humains
Porte de mise en production	Critères explicites à satisfaire avant tout élargissement d'usage
Compétence (skill)	Workflow d'agent versionné, testé et réutilisable
MCP	Protocole standard qui connecte un agent à des outils et à des sources de données

D. Pour aller plus loin

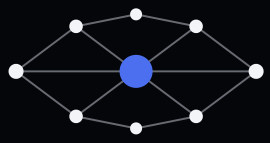
Les projets suivants sont des dépôts publics, en bêta publique pour la plupart. Ils décrivent des conceptions et des cadres, pas des garanties de production.

- **NOVA** : plateforme d'agents de travail produit. github.com/yassineaqejjaj/NOVA
- **ORBIT** : contexte et mémoire gouvernés pour agents. github.com/yassineaqejjaj/ORBIT
- **FORGE** : laboratoire d'évaluation d'agents. github.com/yassineaqejjaj/FORGE
- **TrustRail** : politiques, validation humaine et reçus signés pour actions d'agents. github.com/yassineaqejjaj/TrustRail
- **agentic-sdlc** : autonomie gagnée pour les agents de code (licence MIT). github.com/yassineaqejjaj/agentic-sdlc

Des articles détaillés sont disponibles sur **iaseen.com/blog**. Un second livre blanc, **Le guide de l'AI Factory**, décrit l'organisation qui produit ces systèmes de façon répétable.

À PROPOS DE L'AUTEUR

Yassine Aqejjaj dirige l'AI Factory de Devoteam. Il compte 13 ans d'expérience dans la construction de produits d'IA et de modèles opérationnels, dans la défense, les services publics, le retail et les services financiers. Il a formé plus de 1500 professionnels et publié quatre livres sur l'IA et le leadership. iaseen.com



Construisons la suite.

Un échange sur votre transformation agentique, un retour sur ce guide ou une intervention : écrivez-moi.

IASEEN.COM · LINKEDIN.COM/IN/YASSINE-AQEJJAJ

© 2026 YASSINE AQEJJAJ. CE DOCUMENT EST FOURNI À TITRE INFORMATIF. LES INDICATEURS CITÉS PROVIENNENT DE LA PLATEFORME NOVA DE L'AI FACTORY DE DEVOTEAM ET SONT COMMUNIQUÉS AVEC LEUR MÉTHODE DE CALCUL SUR DEMANDE. LES NIVEAUX D'AUTONOMIE, LA MATRICE DE SÉLECTION ET LA FEUILLE DE ROUTE SONT DES CADRES RECOMMANDÉS, À ADAPTER À CHAQUE ORGANISATION.